

SELEÇÃO BRASILEIRA Copa do Mundo FIFA 2026

Previsão de Convocação — Pipeline de Machine Learning (v10)

Projeto de portfólio — Análise de Dados & Machine Learning

Técnico	Carlo Ancelotti (desde junho/2025)
Período	19/12/2022 – 31/03/2026
Dataset	422 registros · 91 jogadores · 16 janelas FIFA
Modelo	Gradient Boosting Regressor
Target	Média de recência Ancelotti (ajustado por lesão)
Otimização	ILP via PuLP — cotas por sub-posição
Convocação real	18/05/2026 · Museu do Amanhã · Rio de Janeiro
Gerado em	17/05/2026 15:13

Tech Stack & Competências

Python: Pandas, scikit-learn, XGBoost, PuLP, Matplotlib, ReportLab

Machine Learning: Regressão supervisionada, validação cruzada, feature engineering

Otimização: Programação Linear Inteira (ILP) com restrições de negócio

Engenharia de Dados: Limpeza, deduplicação, imputação, agregação temporal

Análise de Domínio: Integração de conhecimento de futebol para corrigir o modelo

Comunicação: Relatório técnico auditável com 10 versões documentadas

0. Contexto e Problema de Negócio

Este projeto demonstra a aplicação de Machine Learning em um problema real de seleção e ranking: prever quais 91 jogadores elegíveis serão incluídos em um grupo de 26. O domínio é futebol, mas o problema é generalista — qualquer processo de seleção com dados históricos de avaliação segue a mesma lógica.

Por que este projeto é relevante para data scientists?

- Dataset longitudinal (múltiplas observações por entidade ao longo do tempo) — requer agregação temporal cuidadosa.
- Target não está diretamente no dataset — é construído a partir de heurísticas de domínio.
- Regras de negócio rígidas (cotas por posição) precisam ser integradas via otimização combinatória, não só via ML.
- Problemas de qualidade de dados reais: chaves duplicadas, NULLs estruturais, variável-alvo com circularidade.
- Decisões de modelagem afetam diretamente o output — cada versão documenta o raciocínio.

1. Arquitetura do Pipeline

O pipeline foi desenvolvido em 10 versões iterativas, cada uma corrigindo um problema identificado através de análise crítica dos resultados ou validação com especialista do domínio.



Fig. 1 — Arquitetura completa do pipeline. Cada etapa alimenta a seguinte; overrides de domínio são aplicados antes do ILP.




Fig. 2 — Competências aplicadas no projeto.

2. Dataset & Qualidade dos Dados

2.1 Estrutura

422 registros (1 linha por jogador × janela FIFA). Apenas jogadores convocados ao menos uma vez aparecem — não há exemplos negativos explícitos. O modelo infere negativos pela ausência.

Dimensão	Valor	Observação
Linhas	422	1 removida (Danilo duplicado — erro de exportação)
Jogadores únicos	91	Chave: player_id (ex: Bremer1997)
Janelas FIFA	16	Mar/23 – Mar/26
Técnicos	4	Menezes, Diniz, Dorival Jr., Ancelotti
Fontes	2	Sofascore (performance) + Transfermarkt (market value, DOB)

3. Feature Engineering

As 422 linhas são agregadas em 91 (1 por jogador). 20 features construídas em 4 grupos:

Grupo	Features	Racional
G1 — Ancelotti (core)	n_anc, mean_rec, coverage, called_l3, avg_sr, anc_rec	Dependência direta do técnico que vai à Copa — peso dominante
G2 — Forma pelo Clube	w_avg_sc, w_min_c, avg_gpc, lt_enc, inj	Nível de atividade e performance no clube no período recente
G3 — Histórico NT	tmnt, wmnt, tgnt, asnt, comp_weight	Experiência e desempenho acumulado pela seleção no ciclo
G4 — Contexto	has_alt_pos, n_calls_total, rep_rate, age	Versatilidade, histórico geral e idade na Copa

Pesos de Recência por Janela

Cada janela recebe peso proporcional à proximidade da Copa. Janelas Ancelotti: Jun/25=0.60 → Mar/26=1.00 (total=4.00). Janelas anteriores: Mar/23=0.02 → Mar/25=0.40.

4. Variável-Alvo — Construção e Justificativa

4.1 Evolução em 10 versões

4.2 Fórmula final

Alisson, Ederson, Bremer (lesão documentada):

```
target = sum(ANC_W[w] for w in called_windows) / n_called
```

Todos os demais:

```
target = sum(ANC_W[w] for w in called_windows) / 4.00
```

Versão	Target	Problema
v1-v2	called_march_2026 (binário)	Circularidade: Gabriel Sara (1 conv.) > Bruno Guimarães (4 conv.)
v3	sum(pesos)/4.00	Penalizava lesionados: Ederson (0.475) abaixo de Hugo Souza (0.750)
v7	sum(pesos)/n_conv. para TODOS	Inflava jogadores com 1 conv.: prob=1.000 para Sara, Bremer, Rayan
v9-v10	÷n_conv. SÓ para Alisson, Ederson, Bremer, Sara e Rayan	Solução única — resolve os 3 casos sem afetar o resto

Resultado para goleiros

Goleiro	GK windows	Denom.	Target	Prob.
Bento	5/5 (todas)	4.00	1.000	0.997
Ederson	2/5 (Nov/25+Mar/26)	1.90 (÷n)	0.950	0.946
Alisson	3/5 (Jun+Set+Mar)	2.30 (÷n)	0.767	0.764
Hugo S.	4/5 orig.	4.00	0.750	0.749

5. Modelos de Machine Learning

Problema reformulado como regressão contínua (0–1). 4 modelos testados com validação cruzada 5-fold:

Modelo	Configuração	R ²	MAE
Ridge Regression	alpha=1.0	0.998	0.011
Random Forest	n=200, max_depth=4, min_leaf=3	0.990	0.017
Gradient Boosting ★	n=200, depth=3, lr=0.05, sub=0.8	0.999	0.006
SVR	RBF kernel, C=1.0, eps=0.05	0.897	0.075

Gradient Boosting selecionado: maior R² e menor MAE. R²≈0.999 reflete alta colinearidade entre target e features Ancelotti — o ML contribui nas margens (ordenação de jogadores com scores similares).

Com N=91 amostras, modelos simples competem com modelos complexos. A regularização foi aplicada em todos.




Fig. 3 — Comparação de métricas (versão de classificação binária, v2).




Fig. 4 — Importância das features (Gradient Boosting). n_anc e coverage dominam.

6. Otimização ILP

Programação Linear Inteira (PuLP + solver CBC) converte probabilidades do modelo em lista de 26 jogadores, maximizando a soma das probabilidades respeitando cotas por sub-posição.

6.1 Por que ILP e não só ranking?

Um ranking simples não garante cotas de posição. Sem ILP, o modelo poderia selecionar 5 laterais direitos e 0 goleiros — matematicamente correto (maximiza probabilidade total), mas inutilizável na prática. O ILP força as restrições de negócio dentro da otimização.

6.2 Cotas por sub-posição (inovação central)

Versões anteriores separavam apenas por posição genérica (Defensor, Meia, etc). A separação por lado do campo foi adicionada após o ILP selecionar 5 laterais direitos e 4 zagueiros esquerdos em versões anteriores:

6.3 Overrides manuais

Grupo	Min	Max	Decisão de design
Goalkeeper	3	3	Fixo — sempre 3 goleiros em Copa
CB_R (Zag. Dir.)	2	2	Separado por lado após erro v5
CB_L (Zag. Esq.)	2	2	Separado por lado após erro v5
RB (Lat. Dir.)	2	2	Danilo (override 1.0) + 1
LB (Lat. Esq.)	2	2	Separado após 5 lat. dir. em v6
Midfielder	4	6	Flexível — 2 vagas flutuantes
Forward	9	11	Resto — min. 9 com 6 meias
TOTAL	26	26	

Jogador	Override	Motivo
Danilo1991	1.00	Confirmado pelo Ancelotti publicamente
Neymar1992	0.40	Calculado via análise de notícias (16/05/2026)
Rodrygo2001	0.00	Lesão confirmada
ÉderMilitão1998	0.00	Lesão confirmada
Estêvão2007	0.00	Lesão confirmada (7 conv. Ancelotti)

7. Caso Especial: Neymar

O modelo atribui probabilidade ≈ 0.000 ao Neymar com base nos dados disponíveis (zero janelas Ancelotti; dados de clube apenas de 2023-2025). Sua situação atual (maio/2026) não está no dataset. A probabilidade de 0.40 foi calculada por análise qualitativa de notícias.

Sinais coletados (16/05/2026):

5 sinais positivos (incluindo do próprio técnico) $\times$ 3 negativos (incluindo forte). Resultado: **0.40** — possível mas não provável. Suficiente para o ILP incluí-lo na 9ª vaga de atacante.

Fonte	Sinal	Dir.
Ancelotti (direta)	Melhorou muito, está jogando com continuidade	↑ Forte
Ancelotti filho	Se está na lista é porque está melhorando	↑
Mauro Beting	Nunca esteve tão próximo da convocação	↑
André Rizek	Improvável que Ancelotti leve. Não acho que jogue para estar nos 26	↓ Forte
Contexto	13 países credenciados — pressão internacional enorme	↑ neutro
Contexto	Santos abaixo do esperado na temporada	↓

8. Histórico de Iterações — v1 a v10

Cada versão corrigiu um problema identificado na análise crítica. Este histórico demonstra o processo real de desenvolvimento de um pipeline de ML — não é linear, e cada erro encontrado agrega valor.

Versão	Problema identificado	Correção aplicada
v1	player_name como chave - dois Danilos confundidos	player_id como chave primária
v2	Target binário com circularidade (Sara > Bruno G.)	Target contínuo: weighted Ancelotti presence
v3	Posições canônicas incorretas (M. Cunha como Meia)	Posição mais frequente por player_id
v4	Hugo Souza inflado (0.838); Ederson penalizado (0.474)	Feature anc_min_per_win; cobertura lista original
v5	ILP escolheu 4 zagueiros esq. (sem distinção de lado)	Classificação CB_R / CB_L com player_ids exatos
v6	ILP escolheu 5 laterais dir. (sem distinção de lado)	Classificação RB / LB; cotas ILP por lado
v7	Fórmula mean_rec para TODOS inflava n=1 (prob=1.000)	Penalidade n=1 global - rejeitada por efeitos colaterais
v8	Penalidade global excessiva - Rayan/Endrick injustiçados	Ajuste só para Alisson e Ederson (/ n_conv.)
v9	Bremer penalizado por lesão ACL (1 conv. Ancelotti)	Bremer adicionado à lista de lesão abonada
v10	Neymar com override arbitrário (0.30)	Probabilidade 0.40 calculada por análise de notícias

9. Lista Final — 26 Convocados + Próximos

ILP v10 com todas as correções aplicadas. Convocação real: 18/05/2026.

#	Jogador	Sub-posição	Target	n Anc.	Prob.	Obs.
1	Bento	Goleiro	1.000	5	0.997	
2	Ederson	Goleiro	0.950	2	0.946	lesão abonada
3	Alisson	Goleiro	0.767	3	0.764	lesão abonada
■	Hugo Souza	Goleiro	0.750	4	0.749	próximo
4	Bremer	Zag. Dir.	1.000	1	0.993	lesão abonada
5	Marquinhos	Zag. Dir.	0.800	4	0.804	
■	Fabrizio Bruno	Zag. Dir.	0.600	3	0.605	próximo
6	Gabriel Magalhães	Zag. Esq.	0.850	4	0.851	
7	Lucas Beraldo	Zag. Esq.	0.350	2	0.352	
■	Alexsandro Ribeiro	Zag. Esq.	0.325	2	0.325	próximo
8	Danilo	Lat. Dir.	0.625	3	1.000	confirmado
9	Wesley	Lat. Dir.	1.000	5	0.999	
■	Vanderson	Lat. Dir.	0.325	2	0.324	próximo
10	Alex Sandro	Lat. Esq.	0.625	3	0.627	
11	Douglas Santos	Lat. Esq.	0.625	3	0.622	
■	Caio Henrique	Lat. Esq.	0.600	3	0.595	próximo
12	Casemiro	Meia	1.000	5	0.998	
13	Andrey Santos	Meia	0.800	4	0.800	
14	Bruno Guimarães	Meia	0.750	4	0.752	
15	Lucas Paquetá	Meia	0.600	3	0.602	
16	Fabinho	Meia	0.475	2	0.479	
17	Joelinton	Meia	0.375	2	0.368	
■	Danilo (BOT)	Meia	0.250	1	0.253	próximo
18	Matheus Cunha	Atacante	1.000	5	0.998	
19	Luiz Henrique	Atacante	0.850	4	0.849	
20	Vinícius Júnior	Atacante	0.825	4	0.823	
21	G. Martinelli	Atacante	0.775	4	0.774	
22	Richarlison	Atacante	0.750	4	0.743	
23	João Pedro	Atacante	0.650	3	0.652	
24	Raphinha	Atacante	0.575	3	0.579	
25	Neymar	Atacante	0.000	0	0.400	notícias 16/05
26	Endrick	Atacante	0.250	1	0.254	
■	Igor Thiago	Atacante	0.250	1	0.254	próximo

■ = próximo mais provável · n Anc. = convocações originais pelo Ancelotti




Fig. 5 — Probabilidade prevista — 91 jogadores. Borda verde = selecionado pelo ILP.

Score de Forma: 40% score clube · 25% minutos · 20% liga · 15% NT




Fig. 6 — Heatmap de performance por posição (score de forma, período Mar/26).

10. Limitações e Próximos Passos

10.1 Limitações

10.2 Próximos Passos

- **N=91 amostras:** Limite inferior para ML supervisionado. Modelos simples preferíveis a complexos — regularização aplicada em todos.
- **Apenas exemplos positivos:** Dataset não contém jogadores nunca convocados. Coleta de negativos explícitos expandiria para ~1440 linhas.
- **5 janelas Ancelotti:** O técnico da Copa tem dados limitados. Preferências táticas específicas sub-representadas.
- **Neymar sem dados recentes:** Sem dados de clube 2025-2026 no dataset. Override via análise de notícias — não dados brutos.
- **Contexto não modelado:** Lesões de última hora, dinâmica de vestiário, preferências táticas — nenhum desses fatores é quantificável.
- **Validação pós-convocação:** Calcular Precision@26 e Recall@26 em 18/05/2026.
- **Coletar negativos:** ~1440 linhas com jogadores não convocados por janela.
- **market_value_eur:** JOIN com data_players_brazil via sofascore_id.
- **Dashboard Streamlit:** Filtros, squad builder, radar de jogador.
- **11 seleções:** Replicar pipeline para Argentina, França, Alemanha etc.

Gerado em 17/05/2026 15:13 | Python · Pandas · scikit-learn · XGBoost · PuLP · ReportLab · Matplotlib · SQLite

Validação real: 18/05/2026 · Museu do Amanhã · Rio de Janeiro